

Teoria dei valori estremi univariati: distribuzione di Pareto generalizzata

Relazione per il corso di Statistica Ambientale M

Luca Iaria

27 gennaio 2026

Sommario

La modellazione dei valori estremi univariati è una componente centrale della statistica applicata, in quanto permette di quantificare la probabilità di eventi rari o anomali nel tempo. In climatologia, tali eventi includono episodi di caldo o freddo estremo, che possono avere effetti rilevanti su ecosistemi, infrastrutture e attività umane.

Coles fornisce diversi approcci per la modellazione dei valori estremi univariati, tra cui il metodo dei massimi a blocchi basato sulla distribuzione dei valori estremi generalizzata (GEV), l'approccio a soglia tramite la distribuzione di Pareto generalizzata (GPD), il metodo degli r -largest order statistics e i modelli basati su processi di punto. Ciascun approccio si fonda su ipotesi differenti e risulta più o meno appropriato a seconda della struttura dei dati e degli obiettivi dell'analisi.

Nel contesto delle temperature giornaliere, l'approccio a soglia risulta particolarmente adatto poiché consente di utilizzare in modo intuitivo ed efficiente le osservazioni estreme senza ricorrere a un'aggregazione temporale dei dati. Per questo motivo, la distribuzione di Pareto generalizzata (GPD) rappresenta un modello naturale per descrivere il comportamento delle eccedenze oltre una soglia elevata e viene adottata come strumento di analisi nel presente approfondimento.

La relazione si articola in tre sezioni. Nella prima sezione viene introdotto il modello GPD nel caso di dati stazionari e indipendenti. La seconda sezione affronta il problema della dipendenza temporale e della non stazionarietà. Infine, nell'ultima sezione viene presentata un'applicazione del modello alle temperature minime giornaliere di Milano, utilizzando il software **R** e il pacchetto **extRemes**.

Indice

1	Modelli a soglia: distribuzione di Pareto generalizzata (GPD)	3
1.1	Introduzione alla modellazione dei valori estremi	3
1.2	Introduzione al metodo a soglia	3
1.3	Teoria dei Valori Estremi: dalla GEV alla GPD	4
1.4	Distribuzione degli eccessi	5
1.5	Scelta della soglia u	5
1.6	Stima dei parametri	6
1.7	Livelli di ritorno	6
1.8	Diagnostica del modello	7
2	GPD per dati dipendenti o non stazionari	8
2.1	Controllo della dipendenza a lungo raggio: la condizione $D(u_n)$	9
2.2	Dipendenza a breve termine e indice estremoale	9
2.3	Declustering	10
2.4	Livelli di ritorno con declustering	10
2.5	Gestione del trend a lungo termine	11
2.6	Gestione della Stagionalità	11
2.7	Selezione del modello	11
2.8	Diagnostica del modello per dati non stazionari	12
3	Applicazione: temperature minime giornaliere a Milano	13
3.1	Analisi esplorativa	13
3.2	Stima del modello GPD	15
3.3	Selezione del modello: GPD vs esponenziale	15
3.4	Diagnostica	16
3.5	Livelli di ritorno	17
3.6	Considerazioni conclusive	18
	Codice R	19
	Bibliografia	24

1 Modelli a soglia: distribuzione di Pareto generalizzata (GPD)

1.1 Introduzione alla modellazione dei valori estremi

La **teoria dei valori estremi** (EVT) ha come obiettivo principale l'estrapolazione del comportamento delle code di una distribuzione. Dato un insieme di variabili casuali indipendenti $X_1, \dots, X_n$ provenienti da una distribuzione sconosciuta F , l'obiettivo è stimare in modo accurato la probabilità di eventi estremi, ossia le caratteristiche della coda di F .

Questa operazione è generalmente complessa poiché:

- i dati sono naturalmente concentrati attorno al centro della distribuzione, mentre le osservazioni estreme sono rare;
- spesso è necessario stimare quantili oltre il massimo osservato $X_{\max}$;
- le tecniche standard di stima della densità funzionano bene dove i dati sono densi, ma risultano poco affidabili nella stima delle probabilità di coda.

Le applicazioni della EVT sono numerose e includono lo studio di temperature estreme, rendimenti finanziari (minimi e massimi giornalieri), velocità estreme del vento, livelli di marea, precipitazioni intense e fenomeni analoghi.

Esistono diversi approcci per modellare la coda di una distribuzione, tra cui:

- **Distribuzione GEV (generalized extreme value)**: è il modello teorico classico per la modellazione dei massimi (o minimi) di blocchi temporali, tipicamente annuali. Sebbene sia semplice e ben interpretato, utilizza un numero limitato di osservazioni e non sfrutta tutta l'informazione disponibile quando i dati sono ad alta frequenza.
- **r -largest order statistic**: estende il modello GEV considerando, per ciascun blocco, gli r valori più grandi. Questo approccio consente di aumentare l'informazione utilizzata, ma richiede una scelta delicata di r e può includere osservazioni che non rappresentano eventi veramente estremi.
- **Processi di punto**: un approccio che modella simultaneamente la frequenza temporale degli eventi e la loro intensità. Sebbene teoricamente generale, risulta meno intuitivo e più complesso rispetto agli altri approcci.
- **GPD (generalized Pareto distribution)**: l'approccio a soglia, basato sulla distribuzione di Pareto generalizzata, descrive il comportamento delle eccedenze oltre una soglia sufficientemente elevata. Rispetto ai modelli a blocchi, consente di utilizzare un numero maggiore di osservazioni estreme mantenendo una struttura concettualmente semplice e flessibile.

1.2 Introduzione al metodo a soglia

Quando si lavora con serie storiche ad alta frequenza, come dati giornalieri o orari, non è sempre consigliabile utilizzare modelli basati su blocchi temporali per estrarre i valori estremi.

Sia $X_1, \dots, X_n$ una sequenza di variabili aleatorie indipendenti e identicamente distribuite da una distribuzione marginale F . È possibile modellare un evento X_i che eccede una certa soglia u attraverso la **probabilità condizionata**. Definito l'eccesso $Y = X - u$, si ha:

$$P(X > u + y \mid X > u) = \frac{1 - F(u + y)}{1 - F(u)}, \quad y > 0.$$

Se la distribuzione F fosse nota, anche la distribuzione dei valori sopra la soglia sarebbe nota. Tuttavia, in contesti applicativi F è generalmente sconosciuta, e si ricorre a una stima basata sulla teoria dei valori estremi, che porta naturalmente alla **distribuzione di Pareto generalizzata (GPD)** per modellare le eccedenze y .

1.3 Teoria dei Valori Estremi: dalla GEV alla GPD

Sia $X_1, \dots, X_n$ una sequenza di variabili casuali i.i.d. con funzione di distribuzione F . La distribuzione del massimo a blocchi:

$$M_n = \max\{X_1, \dots, X_n\}$$

è data da:

$$P(M_n \leq z) = P(X_1 \leq z, \dots, X_n \leq z) = \prod_{i=1}^n F(z) = F(z)^n.$$

Secondo il **teorema di Fisher-Tippett-Gnedenko**, se esistono sequenze di normalizzazione $a_n > 0$ e b_n tali che, per $n \rightarrow \infty$,

$$P\left(\frac{M_n - b_n}{a_n} \leq z\right) \rightarrow G(z),$$

allora G è una distribuzione non degenera e appartiene alla famiglia delle **distribuzioni generalizzate dei valori estremi (GEV)**, che include le classi Gumbel, Fréchet e Weibull. In altre parole, la distribuzione dei massimi a blocchi è legata in modo univoco al comportamento della coda della distribuzione originale F .

Questa connessione teorica permette di modellare i valori estremi che eccedono una soglia elevata u tramite la **distribuzione di Pareto generalizzata (GPD)**. Per n sufficientemente grande, la distribuzione dei massimi può essere approssimata da una GEV con parametri di posizione μ , scala $\sigma > 0$ e forma ξ :

$$F^n(z) \approx \exp \left\{ - \left[1 + \xi \left(\frac{z - \mu}{\sigma} \right) \right]^{-1/\xi} \right\}.$$

Prendendo il logaritmo naturale si ottiene:

$$n \ln(F(z)) \approx - \left[1 + \xi \left(\frac{z - \mu}{\sigma} \right) \right]^{-1/\xi}.$$

Applicando l'espansione di Taylor $\ln(F(z)) \approx -(1 - F(z))$ per valori z nella coda destra (dove $F(z) \rightarrow 1$), otteniamo una stima della probabilità di coda della distribuzione originale:

$$1 - F(z) \approx \frac{1}{n} \left[1 + \xi \left(\frac{z - \mu}{\sigma} \right) \right]^{-1/\xi}.$$

Sostituendo z con $u + y$, la probabilità condizionata che X superi $u + y$ dato che ha superato u è:

$$P(X > u + y \mid X > u) = \frac{1 - F(u + y)}{1 - F(u)} \approx \left[1 + \frac{\xi y}{\sigma + \xi(u - \mu)} \right]^{-1/\xi}.$$

Introducendo il parametro di scala modificato $\tilde{\sigma} = \sigma + \xi(u - \mu)$, otteniamo la forma standard della GPD:

$$H(y) = 1 - \left[1 + \xi \frac{y}{\tilde{\sigma}} \right]^{-1/\xi}, \quad \text{con } \left\{ y : y > 0, 1 + \xi \frac{y}{\tilde{\sigma}} > 0 \right\}.$$

I parametri della GPD sono **scale** ($\tilde{\sigma}$) e **shape** (ξ), dove ξ è identico al parametro di forma della GEV corrispondente.

Analisi dei Minimi Poiché la teoria classica dei valori estremi è formulata per la distribuzione dei massimi, l'analisi dei minimi viene ricondotta a quella dei massimi attraverso una trasformazione di segno. Definito il **minimo campionario** come m_n , vale la relazione:

$$m_n = \min\{X_1, \dots, X_n\} = -\max\{-X_1, \dots, -X_n\}$$

Di conseguenza, l'analisi GPD viene effettuata sulla variabile trasformata $W_i = -X_i$, fissando una soglia u per gli eccessi di W . Per ritornare alla distribuzione originale dei minimi: la soglia corrisponde a $-u$, mentre il parametro di forma ξ descrive la pesantezza della coda di sinistra.

1.4 Distribuzione degli eccessi

Si considerino tre distribuzioni note: esponenziale negativa, Fréchet standard e $U(0, 1)$. L'obiettivo è ricavare la forma della Pareto generalizzata analizzando il limite della distribuzione degli eccessi $Y = X - u$.

Esponenziale negativa Sia $F(x) = 1 - e^{-x}$ per $x > 0$. Calcolando la probabilità condizionata per l'eccesso y :

$$\frac{1 - F(u + y)}{1 - F(u)} = \frac{e^{-(u+y)}}{e^{-u}} = e^{-y}.$$

Questo risultato è valido per ogni $u > 0$ e corrisponde a una GPD con parametro di forma $\xi = 0$ e scala $\tilde{\sigma} = 1$ (distribuzione esponenziale standard).

Fréchet standard Sia $F(x) = \exp(-1/x)$ per $x > 0$. Per $u \rightarrow \infty$, utilizzando l'approssimazione $1 - e^{-w} \approx w$:

$$\frac{1 - F(u + y)}{1 - F(u)} = \frac{1 - \exp\{-(u + y)^{-1}\}}{1 - \exp\{-u^{-1}\}} \approx \frac{(u + y)^{-1}}{u^{-1}} = \left(1 + \frac{y}{u}\right)^{-1}.$$

Questo corrisponde asintoticamente a una GPD con $\xi = 1$ e $\tilde{\sigma} = u$ (coda pesante).

Uniforme (0,1) Sia $X \sim U(0, 1)$, quindi $F(x) = x$ per $0 \leq x \leq 1$. Per un eccesso y tale che $0 \leq y \leq 1 - u$:

$$\frac{1 - F(u + y)}{1 - F(u)} = \frac{1 - (u + y)}{1 - u} = 1 - \frac{y}{1 - u}.$$

Questo risultato corrisponde a una GPD con $\xi = -1$ e $\tilde{\sigma} = 1 - u$ (distribuzione a coda finita).

In sintesi, il valore di ξ determina il *comportamento della coda*:

- $\xi < 0$: la distribuzione degli eccessi ha un limite superiore finito $u - \tilde{\sigma}/\xi$;
- $\xi = 0$: la distribuzione degli eccessi è di tipo esponenziale (coda leggera). Essa corrisponde alla distribuzione esponenziale negativa di parametro $1/\tilde{\sigma}$;
- $\xi > 0$: la distribuzione degli eccessi ha una coda pesante senza limite superiore.

1.5 Scelta della soglia u

Il primo passo per costruire il modello è scegliere la soglia u . Questa scelta è governata dal **trade-off bias-varianza**:

- **Soglia alta** $\Rightarrow$ bassa distorsione (bias) ma alta varianza (pochi eccessi disponibili per la stima);
- **Soglia bassa** $\Rightarrow$ bassa varianza ma alto bias (l'approssimazione asintotica alla GPD potrebbe non essere valida).

In pratica, bisogna scegliere la soglia più bassa possibile compatibilmente con la validità del modello asintotico. Esistono due metodi grafici principali per guidare questa scelta:

Mean residual life plot Questo metodo si basa sulla media della distribuzione GPD. Se $Y = X - u$ segue una GPD, il valore atteso degli eccessi è una funzione lineare della soglia u . Empiricamente, si traccia il grafico dei punti medi degli eccessi al variare di u :

$$\left\{ \left(u, \frac{1}{n_u} \sum_{i=1}^{n_u} (x_{(i)} - u) \right) : u < x_{\max} \right\}$$

La soglia u ottimale viene identificata nel punto in cui il grafico inizia a mostrare un andamento approssimativamente lineare. Al grafico possono essere aggiunti intervalli di confidenza basati sulla normalità approssimata delle medie campionarie.

Stabilità dei parametri Questo approccio valuta la stabilità delle stime GPD al variare della soglia. Se la GPD è valida per u_0 , deve esserlo anche per $u > u_0$. Le proprietà teoriche implicano che, al netto della variabilità campionaria:

- il parametro di forma stimato $\hat{\xi}$ deve rimanere costante;
- il parametro di scala riparametrizzato $\hat{\sigma}^* = \hat{\sigma}_u - \hat{\xi}u$ deve rimanere costante.

Si sceglie la soglia minima a partire dalla quale le stime di $\hat{\xi}$ e $\hat{\sigma}^*$ si stabilizzano. Gli intervalli di confidenza per $\hat{\xi}$ sono ottenuti immediatamente dalla matrice di covarianze degli stimatori dei parametri, mentre gli intervalli di confidenza per $\hat{\sigma}^*$ richiedono il metodo delta.

1.6 Stima dei parametri

Dopo aver determinato la soglia u , i parametri della GPD $\tilde{\sigma}$ e ξ possono essere stimati attraverso il **metodo della massima verosimiglianza**. Siano $y_1, \dots, y_k$ i k eccessi della soglia u .

Per $\xi \neq 0$, la log-verosimiglianza è definita come:

$$\ell(\tilde{\sigma}, \xi) = -k \log \tilde{\sigma} - \left(1 + \frac{1}{\xi}\right) \sum_{i=1}^k \log \left(1 + \xi \frac{y_i}{\tilde{\sigma}}\right)$$

a condizione che $1 + \xi \frac{y_i}{\tilde{\sigma}} > 0$ per ogni $i = 1, \dots, k$; in caso contrario $\ell(\tilde{\sigma}, \xi) = -\infty$.

Nel caso in cui $\xi = 0$, la log-verosimiglianza diventa:

$$\ell(\tilde{\sigma}) = -k \log \tilde{\sigma} - \frac{1}{\tilde{\sigma}} \sum_{i=1}^k y_i.$$

La massimizzazione della verosimiglianza avviene attraverso tecniche numeriche, tenendo conto di una possibile instabilità quando $\xi \approx 0$. Gli standard error e gli intervalli di confidenza per i parametri della GPD sono ottenuti attraverso gli approcci standard della teoria della verosimiglianza.

Secondo [Smith](#), le **proprietà di regolarità** degli stimatori di massima verosimiglianza per la GPD dipendono dal parametro di forma ξ :

- Se $\xi > -0.5$, gli stimatori sono regolari.
- Se $-1 < \xi \leq -0.5$, gli stimatori esistono ma sono irregolari.
- Se $\xi \leq -1$, gli stimatori di massima verosimiglianza non esistono.

1.7 Livelli di ritorno

L'interpretazione diretta dei parametri della distribuzione di Pareto generalizzata non è sempre immediata. Per questo motivo, nell'analisi dei valori estremi si ricorre spesso ai **livelli di ritorno**, che rappresentano quantili estremi della distribuzione delle eccedenze sopra una soglia elevata.

Siano $X_1, \dots, X_n$ variabili aleatorie i.i.d. con funzione di distribuzione F , e sia u una soglia sufficientemente alta. Per $x > u$, la distribuzione condizionata degli eccessi è approssimata dalla GPD:

$$P(X > x \mid X > u) \approx \left(1 + \xi \frac{x - u}{\tilde{\sigma}}\right)^{-1/\xi},$$

dove $\tilde{\sigma} > 0$ è il parametro di scala e ξ è il parametro di forma.

Segue che la probabilità incondizionata di superare $x > u$ può essere scritta come:

$$P(X > x) = P(X > u) P(X > x | X > u) = \zeta_u \left(1 + \xi \frac{x - u}{\tilde{\sigma}} \right)^{-1/\xi},$$

dove $\zeta_u = P(X > u)$ indica la probabilità di superamento della soglia.

Si definisce il **livello di ritorno** x_m come il valore che viene superato, in media, una volta ogni m osservazioni, ovvero tale che $P(X > x_m) = 1/m$. Sostituendo nell'espressione precedente si ottiene:

$$\frac{1}{m} = \zeta_u \left(1 + \xi \frac{x_m - u}{\tilde{\sigma}} \right)^{-1/\xi}.$$

Risolvendo rispetto a x_m , si ricava la formula per il livello di ritorno:

$$x_m = \begin{cases} u + \frac{\tilde{\sigma}}{\xi} [(m \zeta_u)^\xi - 1], & \xi \neq 0, \\ u + \tilde{\sigma} \ln(m \zeta_u), & \xi = 0. \end{cases}$$

Per valori sufficientemente grandi di m (tali che $x_m > u$), il grafico dei livelli di ritorno x_m in funzione di m (su scala logaritmica) fornisce informazioni visive immediate sul comportamento della coda:

- **linearità** se $\xi = 0$ (coda esponenziale);
- **convessità** (curvatura verso l'alto) se $\xi > 0$ (coda pesante, dominio di Fréchet);
- **concavità** (curvatura verso il basso) se $\xi < 0$ (coda limitata, dominio di Weibull).

Spesso è conveniente esprimere i livelli di ritorno su scala temporale (annuale). Se n_y indica il numero medio di osservazioni in un anno, il livello di ritorno associato a un periodo di ritorno di N anni corrisponde a porre $m = N \times n_y$. Il **livello di ritorno a N anni** è quindi:

$$z_N = \begin{cases} u + \frac{\tilde{\sigma}}{\xi} [(N n_y \zeta_u)^\xi - 1], & \xi \neq 0, \\ u + \tilde{\sigma} \ln(N n_y \zeta_u), & \xi = 0. \end{cases}$$

Nell'applicazione pratica, i parametri ξ e $\tilde{\sigma}$ vengono sostituiti con le rispettive stime di massima verosimiglianza, mentre ζ_u è stimata in modo naturale dalla proporzione campionaria:

$$\hat{\zeta}_u = \frac{k}{n},$$

dove k è il numero di osservazioni nel campione che superano la soglia u . Gli errori standard e gli intervalli di confidenza per i livelli di ritorno z_N vengono solitamente derivati tramite il metodo delta. Tuttavia, è doveroso precisare che la stima dei livelli di ritorno, così come quella dei parametri GPD, può beneficiare di una quantificazione dell'incertezza più accurata attraverso l'uso della verosimiglianza profilo.

1.8 Diagnostica del modello

Siano $y_{(1)} \leq \dots \leq y_{(k)}$ i valori ordinati delle k osservazioni che eccedono la soglia u , e sia $\hat{H}$ il modello GPD stimato con parametri $(\hat{\sigma}, \hat{\xi})$. È possibile valutare la qualità dell'adattamento attraverso **quattro grafici diagnostici principali**. Per il calcolo delle coordinate empiriche, si definisce la frequenza cumulata $p_i = i/(k + 1)$.

Probability plot: È la rappresentazione grafica delle coppie

$$\left\{ \left(p_i, \hat{H}(y_{(i)}) \right); i = 1, \dots, k \right\},$$

dove la funzione di distribuzione stimata è:

$$\hat{H}(y) = \begin{cases} 1 - \left(1 + \hat{\xi} \frac{y}{\hat{\sigma}} \right)^{-1/\hat{\xi}} & \text{se } \hat{\xi} \neq 0, \\ 1 - \exp \left\{ -\frac{y}{\hat{\sigma}} \right\} & \text{se } \hat{\xi} = 0. \end{cases}$$

In caso di buon adattamento, i punti devono disporsi approssimativamente lungo la diagonale.

Quantile plot: È la rappresentazione delle coppie

$$\left\{ \left(\hat{H}^{-1}(p_i), x_{(i)} \right); i = 1, \dots, k \right\},$$

dove $x_{(i)}$ sono le osservazioni originali sopra soglia ordinate in senso crescente. Il grafico confronta i quantili teorici del modello GPD (riportati alla scala originale) con i dati empirici. La funzione quantile è:

$$\hat{H}^{-1}(p) = \begin{cases} u + \frac{\hat{\sigma}}{\hat{\xi}} \left[(1-p)^{-\hat{\xi}} - 1 \right] & \text{se } \hat{\xi} \neq 0, \\ u - \hat{\sigma} \ln(1-p) & \text{se } \hat{\xi} = 0. \end{cases}$$

In caso di buon adattamento, i punti devono disporsi approssimativamente lungo la diagonale.

Return level plot: È la rappresentazione delle coppie

$$\{(m, \hat{x}_m)\}$$

dove l'asse delle ascisse rappresenta il periodo di ritorno m (generalmente su scala logaritmica) e l'asse delle ordinate il livello di ritorno stimato $\hat{x}_m$. Sul grafico vengono sovrapposti i punti empirici e le curve degli intervalli di confidenza (solitamente al 95%). Se il modello è corretto, i punti empirici dovrebbero ricadere all'interno delle bande di confidenza.

Density function plot: Consiste nel confronto visivo tra l'istogramma campionario (su scala di densità) e la funzione di densità di probabilità stimata $\hat{h}(y)$.

$$\hat{h}(y) = \begin{cases} \frac{1}{\hat{\sigma}} \left(1 + \hat{\xi} \frac{y}{\hat{\sigma}} \right)^{-(1+1/\hat{\xi})} & \text{se } \hat{\xi} \neq 0, \\ \frac{1}{\hat{\sigma}} \exp \left\{ -\frac{y}{\hat{\sigma}} \right\} & \text{se } \hat{\xi} = 0. \end{cases}$$

2 GPD per dati dipendenti o non stazionari

I modelli asintotici discussi finora si fondano sull'ipotesi che la sequenza di variabili casuali sottostante sia **indipendente e identicamente distribuita**. Tuttavia, nelle applicazioni reali, le serie storiche osservate presentano spesso caratteristiche che violano tali assunzioni:

- **Dipendenza a breve termine** (es. la temperatura di oggi è correlata a quella di ieri);

- **Dipendenza a lungo raggio** (nei processi fisici è meno comune)
- **Trend a lungo termine** (es. derive causate dal cambiamento climatico).
- **Stagionalità** (cicli periodici intra-annuali);

Prima di procedere con la modellazione degli estremi, è fondamentale diagnosticare la presenza di tali violazioni. La dipendenza a breve termine viene comunemente indagata attraverso l'analisi delle funzioni di **autocorrelazione globale (ACF)** e **parziale (PACF)**, che quantificano la memoria del processo.

La violazione dell'ipotesi di identica distribuzione (non stazionarietà) viene invece valutata principalmente tramite ispezione grafica, come strumento esplorativo generale. Pur non essendo specifici per il comportamento delle code, possono essere utilizzati test di radice unitaria, come il test **augmented Dickey-Fuller (ADF)**, per individuare la presenza di trend o cambiamenti strutturali nella serie.

Qualora tali test confermino la presenza di dipendenza o non stazionarietà, l'approccio classico deve essere adattato, introducendo tecniche di declustering per gestire la dipendenza e modelli a parametri variabili per catturare l'evoluzione temporale della distribuzione.

2.1 Controllo della dipendenza a lungo raggio: la condizione $D(u_n)$

Per garantire che la teoria asintotica rimanga valida anche in presenza di dipendenza a lungo raggio, è stata introdotta la **condizione $D(u_n)$** . Sia $\{X_n\}_{n \geq 1}$ una successione stazionaria; la condizione $D(u_n)$ è soddisfatta se, per ogni coppia di insiemi di indici

$$i_1 < \dots < i_p < j_1 < \dots < j_q$$

tali che la separazione temporale sia $j_1 - i_p > l_n$, vale la seguente disuguaglianza:

$$\left| P \left(\bigcap_{k=1}^p \{X_{i_k} \leq u_n\} \cap \bigcap_{h=1}^q \{X_{j_h} \leq u_n\} \right) - P \left(\bigcap_{k=1}^p \{X_{i_k} \leq u_n\} \right) P \left(\bigcap_{h=1}^q \{X_{j_h} \leq u_n\} \right) \right| \leq \alpha(n, l_n)$$

dove $\alpha(n, l_n) \rightarrow 0$ per una successione $l_n = o(n)$.

In termini intuitivi, la condizione $D(u_n)$ assicura che, per una sequenza di livelli u_n , gli eventi sufficientemente distanti nel tempo siano asintoticamente indipendenti.

Siano ora $\{a_n\}_{n \geq 1}$ e $\{b_n\}_{n \geq 1}$ successioni di costanti normalizzanti e sia $u_n = a_n x + b_n$. Se la condizione $D(u_n)$ è soddisfatta e se $P(M_n \leq u_n) \rightarrow G(x)$ per una distribuzione non degenere G , allora G deve essere una distribuzione GEV. Questo teorema fondamentale implica che la dipendenza a lungo raggio, purché debole, non altera la forma della distribuzione limite, legittimando l'uso della GEV e di conseguenza del GPD anche per serie temporali non perfettamente indipendenti.

2.2 Dipendenza a breve termine e indice estremale

Sia $\{X_n\}_{n \geq 1}$ una successione stazionaria; la dipendenza a breve termine altera i parametri della distribuzione limite. Tale effetto è catturato dall'**indice estremale** $\theta \in [0, 1]$, definito come:

$$\theta = \lim_{n \rightarrow \infty} P(\max\{X_2, \dots, X_{p_n}\} \leq u_n \mid X_1 > u_n)$$

dove $p_n = o(n)$ e la sequenza u_n è tale che $P(M_n \leq u_n)$ converge. L'indice θ è dato dal reciproco della dimensione media dei cluster di eccessi:

$$\theta \approx \frac{1}{\text{mean cluster size}}$$

- Se $\theta = 1$: i dati sono asintoticamente indipendenti.
- Se $\theta < 1$: gli estremi tendono a raggrupparsi in cluster.

Sia M_n il massimo del processo stazionario dipendente e M_n^* il massimo di una sequenza i.i.d. associata (stessa distribuzione marginale). Se vale la condizione $D(u_n)$ e $\theta > 0$, allora:

$$P\left(\frac{M_n^* - b_n}{a_n} \leq x\right) \rightarrow G_1(z)$$

se e solo se

$$P\left(\frac{M_n - b_n}{a_n} \leq x\right) \rightarrow G_2(z)$$

con la relazione fondamentale:

$$G_2(x) = G_1^\theta(x)$$

Questo risultato dimostra che la distribuzione limite rimane una GEV con lo stesso parametro di forma ξ , ma con parametri di posizione (μ) e scala (σ) modificati:

$$\begin{cases} \mu^* = \mu - \frac{\sigma}{\xi}(1 - \theta^{-\xi}), & \sigma^* = \sigma\theta^\xi & \text{se } \xi \neq 0 \\ \mu^* = \mu + \sigma \ln(\theta), & \sigma^* = \sigma & \text{se } \xi = 0 \end{cases}$$

Le implicazioni di questo risultato teorico si estendono naturalmente all'approccio a soglia sfruttando la relazione asintotica tra GEV e GPD.

2.3 Declustering

Per applicare correttamente la distribuzione generalizzata di Pareto, è necessario rimuovere la dipendenza intra-cluster attraverso una procedura di **declustering**. Questa procedura filtra i dati mantenendo solo il valore più estremo di ogni gruppo, ottenendo un sotto-campione approssimativamente indipendente su cui adattare il modello.

Una tecnica standard per l'identificazione dei cluster considera un cluster attivo finché non si verificano r osservazioni consecutive al di sotto della soglia u . La scelta del parametro r comporta un inevitabile trade-off tra bias e varianza:

- Un valore troppo piccolo di r rischia di separare falsamente un singolo evento in più cluster, compromettendo l'ipotesi di indipendenza.
- Un valore troppo grande tende ad accorpare eventi fisicamente distinti, causando una perdita di informazione preziosa.

In assenza di regole teoriche generali, Coles suggerisce di affidarsi al giudizio empirico e di verificare la sensibilità dei risultati a diverse scelte di r .

Tuttavia, tale approccio sebbene semplice, comporta una perdita di informazione, poiché vengono scartati tutti gli eccessi non massimali all'interno del cluster. Inoltre, le stime possono rivelarsi sensibili alle scelte soggettive dei parametri di declustering.

2.4 Livelli di ritorno con declustering

In presenza di dipendenza a breve termine, il calcolo dei **livelli di ritorno** deve tenere conto dell'indice estemale θ per correggere il tasso di occorrenza degli eventi. Se il periodo di ritorno m è definito rispetto alla scala temporale originale e ζ_u rappresenta la probabilità di superamento della soglia, la formula diventa:

$$x_m = \begin{cases} u + \frac{\sigma}{\xi} [(m \zeta_u \theta)^\xi - 1], & \text{se } \xi \neq 0 \\ u + \sigma \ln(m \zeta_u \theta), & \text{se } \xi = 0 \end{cases}$$

Tuttavia, nel caso in cui il modello sia stimato su dati già declusterizzati, la probabilità di superamento viene stimata direttamente come rapporto tra il numero di cluster e il numero totale di osservazioni ($\hat{\zeta}_u \approx \theta \zeta_{raw}$). Di conseguenza, l'effetto della dipendenza è già incorporato nella stima e si recupera formalmente l'espressione standard presentata nel caso di dati i.i.d.

2.5 Gestione del trend a lungo termine

A differenza della dipendenza temporale, nel caso di *processi non stazionari* (soggetti a trend o stagionalità) non esiste una teoria asintotica generale che garantisca la validità automatica dei modelli limite standard. Si adotta pertanto un approccio pragmatico, utilizzando la GEV o la GPD come modelli di base e permettendo ai loro parametri di dipendere dal tempo o da altre covariate per descrivere l'evoluzione sistematica del processo.

Sia $\{X_t\}_{t \geq 1}$ una sequenza di variabili aleatorie non stazionarie e sia $u(t)$ una soglia elevata, eventualmente variabile nel tempo. La distribuzione degli eccessi $Y_t = X_t - u(t)$ è modellata tramite una distribuzione di Pareto generalizzata definita dalla probabilità condizionata:

$$P(X_t - u(t) \leq y \mid X_t > u(t)) = H_t(y) = 1 - \left(1 + \xi(t) \frac{y}{\tilde{\sigma}(t)}\right)^{-1/\xi(t)}, \quad y > 0.$$

Nella pratica, per garantire la positività del parametro di scala, si utilizza spesso una funzione di legame logaritmica. Il parametro di forma ξ viene frequentemente mantenuto costante per ragioni di stabilità, poiché i dati estremi disponibili raramente consentono una stima affidabile di una sua evoluzione temporale. Un esempio di specificazione con **trend lineare** è:

$$\ln(\sigma(t)) = \beta_0 + \beta_1 t, \quad \xi(t) = \xi.$$

La stima dei parametri avviene mediante massimizzazione della log-verosimiglianza complessiva costruita sulle osservazioni eccedenti la soglia nel periodo di analisi.

2.6 Gestione della Stagionalità

La **stagionalità** è una caratteristica integrante nelle serie ambientali campionate a scala giornaliera o oraria, dovuta ai cicli meteorologici annuali. Tale comportamento viola l'ipotesi di identica distribuzione. Uno degli approcci principali per gestire la stagionalità è la stratificazione stagionale. L'approccio consiste nello specificare un modello con parametri diversi per ogni stagione. Se denotiamo con $s(t)$ la stagione in cui ricade l'osservazione al tempo t , è possibile definire soglie variabili $u_{s(t)}$ specifiche per ciascun periodo. Di conseguenza, gli eccessi sopra la soglia seguono una distribuzione GPD con parametri dipendenti dalla stagione:

$$(X_t - u_{s(t)} \mid X_t > u_{s(t)}) \sim GP(\tilde{\sigma}_{s(t)}, \xi_{s(t)})$$

dove $(\tilde{\sigma}_{s(t)}, \xi_{s(t)})$ sono i parametri di scala e forma nella stagione $s(t)$. Poiché la verosimiglianza si fattorizza attraverso le stagioni, è possibile trattare ogni periodo separatamente, adattando modelli indipendenti per ciascun blocco. Questo approccio non impone forme funzionali rigide ai parametri, ma riduce la numerosità campionaria disponibile per ogni stima.

2.7 Selezione del modello

Dopo aver presentato diverse configurazioni possibili, il passo successivo è la **selezione del modello** più adeguato per il campione osservato. Spesso è necessario confrontare un modello più complesso con uno più semplice e valutare se l'aumento di complessità apporta un miglioramento significativo nell'adattamento ai dati. In caso negativo, è preferibile mantenere il modello più semplice. Esempi tipici includono il confronto tra un modello stazionario e uno con trend lineare, oppure la scelta se lasciare variabile o fissare il parametro di forma ξ nella modellazione stagionale.

Dati due modelli annidati $\mathcal{M}_0$ e $\mathcal{M}_1$, tali che $\mathcal{M}_0 \subset \mathcal{M}_1$, è possibile applicare il **test del rapporto di verosimiglianza generalizzato** basato sulla statistica devianza D .

Si definisce la statistica D come:

$$D = 2\{\ell_1(\mathcal{M}_1) - \ell_0(\mathcal{M}_0)\}$$

dove $\ell_1(\mathcal{M}_1)$ e $\ell_0(\mathcal{M}_0)$ sono le log-verosimiglianze massimizzate rispettivamente per il modello più complesso e per quello più semplice.

Sotto l'ipotesi nulla H_0 che il modello più semplice $\mathcal{M}_0$ sia adeguato, per n grande la statistica D si distribuisce asintoticamente come una variabile casuale Chi-quadro:

$$D \sim \chi_k^2$$

dove k rappresenta la differenza nel numero di parametri tra $\mathcal{M}_1$ e $\mathcal{M}_0$. Grandi valori di D indicano dunque che il modello $\mathcal{M}_1$ spiega una quota sostanziale della variazione dei dati non catturata da $\mathcal{M}_0$. Viceversa, piccoli valori di D suggeriscono che l'aumento di complessità non comporta miglioramenti statisticamente significativi.

2.8 Diagnostica del modello per dati non stazionari

Nel caso in cui i dati originali non sono identicamente distribuiti, non è possibile utilizzare i grafici diagnostici standard per valutare la qualità del modello. È necessario operare su una **versione standardizzata dei dati**.

Data la stima del modello finale, si applica una trasformazione per ricondurre gli eccessi a una distribuzione comune, specificamente la distribuzione esponenziale standard. Definendo X_t come l'osservazione al tempo t e $u(t)$ come la soglia corrispondente, gli eccessi trasformati $\tilde{Y}_t$ sono calcolati come:

$$\tilde{Y}_t = \begin{cases} \frac{1}{\hat{\xi}(t)} \ln \left\{ 1 + \hat{\xi}(t) \left(\frac{X_t - u(t)}{\hat{\sigma}(t)} \right) \right\} & \text{se } \hat{\xi}(t) \neq 0 \\ \frac{X_t - u(t)}{\hat{\sigma}(t)} & \text{se } \hat{\xi}(t) = 0 \end{cases}$$

Indipendentemente dal caso, sotto l'ipotesi di validità del modello le variabili $\tilde{Y}_t$ hanno distribuzione marginale esponenziale standard ($Exp(1)$), indipendentemente dal tempo t .

Dati i valori ordinati dei residui trasformati $\tilde{y}_{(1)} \leq \dots \leq \tilde{y}_{(k)}$, è possibile costruire i grafici diagnostici confrontando i valori empirici con quelli teorici della distribuzione esponenziale standard:

- **Probability plot:** Confronta la probabilità empirica con la funzione di ripartizione teorica $F(y) = 1 - e^{-y}$. I punti rappresentati sono:

$$\left\{ \left(\frac{i}{k+1}, 1 - e^{-\tilde{y}_{(i)}} \right); i = 1, \dots, k \right\}$$

- **Quantile plot:** Confronta i residui ordinati con i quantili teorici dell'esponenziale ($-\ln(1-p)$). I punti rappresentati sono:

$$\left\{ \left(-\ln \left(1 - \frac{i}{k+1} \right), \tilde{y}_{(i)} \right); i = 1, \dots, k \right\}$$

Se il modello è ben specificato, in entrambi i grafici i punti dovrebbero allinearsi lungo la diagonale unitaria.

3 Applicazione: temperature minime giornaliere a Milano

Il pacchetto **GSODR** permette di accedere ai dati meteorologici giornalieri raccolti dal *National Centers for Environmental Information* (NCEI, USA). In questo lavoro sono state analizzate le temperature minime giornaliere registrate dalla stazione di Milano Linate nel periodo 1976–2018, per un totale di 43 anni di osservazioni.

3.1 Analisi esplorativa

Il dataset comprende 15 700 osservazioni giornaliere. Come evidenziato in Figura 1, la serie presenta una marcata stagionalità annuale che viola l'ipotesi di identica distribuzione. Per superare questo problema, i dati sono stati stratificati nelle quattro stagioni meteorologiche:

- **DJF** (inverno): dicembre, gennaio, febbraio;
- **MAM** (primavera): marzo, aprile, maggio;
- **JJA** (estate): giugno, luglio, agosto;
- **SON** (autunno): settembre, ottobre, novembre.

Coerentemente con la teoria presentata nella Sezione 1.3, l'analisi viene condotta sulla variabile trasformata $X = -T_{\min}$, in modo da ricondurre lo studio dei minimi a quello dei massimi.




Figura 1: Serie storica delle temperature minime giornaliere a Milano (1976–2018). La stagionalità annuale è chiaramente visibile.

La Figura 2 mostra le quattro serie stagionali. Visivamente, ciascuna appare stazionaria attorno a un livello medio costante. Tale ipotesi è confermata dal test Augmented Dickey-Fuller (Tabella 1): per tutte le stagioni la statistica test risulta ampiamente inferiore al valore critico all'1%, portando al rifiuto dell'ipotesi nulla di radice unitaria. Il trend deterministico non risulta significativo in nessun caso.

L'analisi delle funzioni di autocorrelazione (Figura 3) rivela una forte dipendenza temporale a breve termine. In tutte le stagioni, l'ACF al primo lag è prossima a 0.8 e decade lentamente, mentre la PACF mostra un picco significativo al lag 1 seguito da valori trascurabili. Questo comportamento, tipico di un processo AR(1), indica che la temperatura di un giorno è fortemente correlata a quella del giorno precedente. L'ipotesi di indipendenza risulta quindi violata, rendendo necessario il ricorso al declustering.

Tabella 1: Test ADF con specificazione trend. Valore critico all'1%: -3.96 .

Stagione	Statistica τ_3	Esito
DJF (inverno)	-17.51	Rifiuto H_0
MAM (primavera)	-14.51	Rifiuto H_0
JJA (estate)	-18.06	Rifiuto H_0
SON (autunno)	-13.69	Rifiuto H_0




Figura 2: Serie storiche stagionali della variabile trasformata $-T_{\min}$.




Figura 3: Funzioni di autocorrelazione (ACF) e autocorrelazione parziale (PACF) per le quattro stagioni.

3.2 Stima del modello GPD

La violazione delle ipotesi di identica distribuzione e indipendenza richiede un approccio in due fasi: (i) stratificazione stagionale per ripristinare la stazionarietà; (ii) declustering per ottenere osservazioni approssimativamente indipendenti.

Scelta della soglia. Il primo passo consiste nell'individuare una soglia u appropriata per ciascuna stagione. Il mean residual life plot (Figura 4) suggerisce le seguenti soglie, scelte come compromesso tra linearità del grafico e numerosità campionaria sufficiente:

$$u_{\text{DJF}} = 5, \quad u_{\text{MAM}} = 0.5, \quad u_{\text{JJA}} = -12.5, \quad u_{\text{SON}} = 0.$$




Figura 4: Mean residual life plot per le quattro stagioni. La soglia ottimale corrisponde al punto in cui il grafico diventa approssimativamente lineare.

Declustering e analisi di sensibilità. Per gestire la dipendenza temporale, è stato applicato il metodo *runs* descritto nella Sezione 2.3. La Tabella 2 riporta i risultati al variare del parametro r (numero di osservazioni consecutive sotto soglia per chiudere un cluster).

Per DJF, MAM e JJA le stime di $\hat{\xi}$ risultano stabili al variare di r , con valori prossimi a zero. L'indice estremo θ si attesta nella fascia 0.3–0.5, indicando una dipendenza marcata: in media, ogni cluster contiene 2–3 eccedenze consecutive.

Il caso SON merita particolare attenzione: la stima di $\hat{\xi}$ varia sensibilmente con r (da -0.38 a -0.60), suggerendo una maggiore incertezza strutturale. Questo comportamento può essere attribuito alla natura transitoria dell'autunno, caratterizzato da un'elevata variabilità meteorologica.

Sulla base di questa analisi, è stato scelto $r = 2$ come valore di riferimento, che offre un buon compromesso tra numerosità dei cluster e stabilità delle stime.

Stime finali GPD. La Tabella 3 riassume le stime ottenute con $r = 2$. Per DJF, MAM e JJA, il parametro di forma $\hat{\xi}$ è prossimo a zero, suggerendo che la distribuzione esponenziale ($\xi = 0$) possa costituire un modello adeguato. Per SON, invece, $\hat{\xi} \approx -0.43$ indica una coda con limite superiore finito.

3.3 Selezione del modello: GPD vs esponenziale

Per verificare formalmente se il modello esponenziale sia adeguato, è stato applicato il test del rapporto di verosimiglianza generalizzato con ipotesi nulla $H_0 : \xi = 0$. Come discusso nella Sezione 2.6, la statistica test $D = 2[\ell_{\text{GPD}} - \ell_{\text{Exp}}]$ segue asintoticamente una distribuzione χ^2_1 .

Tabella 2: Analisi di sensibilità: stime GPD al variare della lunghezza del run r .

Stagione	r	u	n_{exc}	n_{cl}	θ	$\hat{\sigma}$ (s.e.)	$\hat{\xi}$ (s.e.)
DJF	1	5.0	282	123	0.44	2.07 (0.25)	-0.06 (0.08)
	2	5.0	282	97	0.34	2.20 (0.30)	-0.08 (0.09)
	3	5.0	282	87	0.31	2.20 (0.32)	-0.06 (0.10)
	4	5.0	282	83	0.29	2.13 (0.32)	-0.05 (0.10)
MAM	1	0.5	105	64	0.61	1.75 (0.28)	-0.17 (0.10)
	2	0.5	105	54	0.51	1.76 (0.32)	-0.16 (0.12)
	3	0.5	105	49	0.47	1.95 (0.36)	-0.21 (0.12)
	4	0.5	105	47	0.45	1.95 (0.37)	-0.21 (0.12)
JJA	1	-12.5	182	97	0.53	1.69 (0.22)	-0.03 (0.08)
	2	-12.5	182	82	0.45	1.83 (0.25)	-0.05 (0.08)
	3	-12.5	182	74	0.41	1.94 (0.28)	-0.06 (0.08)
	4	-12.5	182	70	0.39	1.97 (0.29)	-0.06 (0.09)
SON	1	0.0	177	84	0.48	2.70 (0.38)	-0.38 (0.10)
	2	0.0	177	67	0.38	2.97 (0.48)	-0.43 (0.12)
	3	0.0	177	56	0.32	3.40 (0.60)	-0.51 (0.13)
	4	0.0	177	51	0.29	3.83 (0.70)	-0.60 (0.15)

Tabella 3: Stime GPD con $r = 2$.

Stagione	u	n_{exc}	n_{cl}	θ	$\hat{\sigma}$ (s.e.)	$\hat{\xi}$ (s.e.)	$-\ell$
DJF	5.0	282	97	0.34	2.20 (0.30)	-0.08 (0.09)	165.61
MAM	0.5	105	54	0.51	1.76 (0.32)	-0.16 (0.12)	75.79
JJA	-12.5	182	82	0.45	1.83 (0.25)	-0.05 (0.08)	127.43
SON	0.0	177	67	0.38	2.97 (0.48)	-0.43 (0.12)	111.27

I risultati (Tabella 4) mostrano che per DJF, MAM e JJA il test non rifiuta H_0 . Per queste stagioni, il modello esponenziale risulta quindi statisticamente equivalente alla GPD completa e viene preferito per parsimonia.

Per SON, invece, il test rifiuta H_0 con $p = 0.004$, confermando la necessità di mantenere il parametro ξ libero. Il valore negativo $\hat{\xi} = -0.43$ implica l'esistenza di un limite superiore finito per la distribuzione degli eccessi, pari a $u - \tilde{\sigma}/\xi \approx 6.9^\circ\text{C}$, ossia un limite inferiore di circa -6.9°C per le temperature minime autunnali. La Tabella 5 riporta i parametri dei modelli finali selezionati.

Tabella 4: Test del rapporto di verosimiglianza: $H_0 : \xi = 0$ (modello esponenziale).

Stagione	Statistica D	p -value	Decisione
DJF	0.72	0.396	Non rifiuto H_0
MAM	1.28	0.259	Non rifiuto H_0
JJA	0.34	0.558	Non rifiuto H_0
SON	8.49	0.004	Rifiuto H_0

3.4 Diagnostica

Per valutare la bontà di adattamento, gli eccessi sono stati trasformati in osservazioni standardizzate secondo la procedura descritta nella Sezione 2.7. Se il modello è corretto, tali osservazioni seguono una distribuzione esponenziale standard.

Tabella 5: Modelli finali selezionati.

Stagione	Modello	u	n_{cl}	θ	$\hat{\sigma}$ (s.e.)	$\hat{\xi}$ (s.e.)
DJF	Esponenziale	5.0	97	0.34	2.04 (0.21)	0 (–)
MAM	Esponenziale	0.5	54	0.51	1.51 (0.21)	0 (–)
JJA	Esponenziale	–12.5	82	0.45	1.74 (0.19)	0 (–)
SON	GPD	0.0	67	0.38	2.97 (0.48)	–0.43 (0.12)

La Figura 5 mostra i grafici PP e QQ per le quattro stagioni. In tutti i casi, i punti si dispongono approssimativamente lungo la diagonale, senza deviazioni sistematiche. Questo conferma l'adeguatezza dei modelli selezionati.




Figura 5: Diagnostica: probability plot (sinistra) e quantile plot (destra) dei residui standardizzati rispetto alla distribuzione $\text{Exp}(1)$.

3.5 Livelli di ritorno

I livelli di ritorno, calcolati secondo la formula presentata nella Sezione 1.7 con la correzione per la dipendenza temporale (θ), sono riportati in Tabella 6. Gli intervalli di confidenza al 95% sono stati ottenuti mediante il metodo delta.

Interpretazione. I risultati riflettono le diverse caratteristiche climatiche delle stagioni:

- **Inverno (DJF):** presenta gli estremi più severi. Il livello di ritorno centenario di -16.0°C è pienamente coerente con il record storico ufficiale della stazione di Milano Linate (-14.4°C , registrato nel gennaio 1985).

Tabella 6: Livelli di ritorno stimati ($^{\circ}\text{C}$) con intervalli di confidenza al 95%.

Stagione	T (anni)	$\hat{z}_T$ ($^{\circ}\text{C}$)	IC 95%
DJF (inverno)	10	-11.3	$[-12.6, -10.1]$
	20	-12.8	$[-14.3, -11.2]$
	50	-14.6	$[-16.5, -12.7]$
	100	-16.0	$[-18.2, -13.8]$
MAM (primavera)	10	-4.3	$[-5.4, -3.3]$
	20	-5.4	$[-6.7, -4.1]$
	50	-6.8	$[-8.4, -5.1]$
	100	-7.8	$[-9.8, -5.9]$
JJA (estate)	10	+7.4	$[+6.3, +8.5]$
	20	+6.2	$[+4.8, +7.5]$
	50	+4.6	$[+2.8, +6.3]$
	100	+3.3	$[+1.4, +5.3]$
SON (autunno)	10	-4.8	$[-5.4, -4.2]$
	20	-5.4	$[-6.0, -4.7]$
	50	-5.9	$[-6.7, -5.1]$
	100	-6.2	$[-7.1, -5.2]$

- **Primavera (MAM):** sebbene meno intensi in valore assoluto rispetto all'inverno, eventi di -7.8°C costituiscono anomalie termiche eccezionali, rappresentando deviazioni drastiche rispetto alla climatologia media stagionale.
- **Estate (JJA):** i livelli di ritorno rimangono positivi anche per $T = 100$ anni. Questo risultato, sebbene statisticamente corretto, ha un'interpretazione fisica limitata: non si tratta di estremi di freddo in senso proprio, ma piuttosto di notti insolitamente fresche per il periodo estivo.
- **Autunno (SON):** la differenza contenuta tra $\hat{z}_{10} = -4.8^{\circ}\text{C}$ e $\hat{z}_{100} = -6.2^{\circ}\text{C}$ è conseguenza diretta del parametro $\xi < 0$, che implica una coda limitata superiormente. Fisicamente, questo riflette il fatto che le temperature autunnali, pur potendo scendere sotto zero, non raggiungono mai i valori estremi tipici dell'inverno.

3.6 Considerazioni conclusive

L'analisi condotta illustra l'applicazione della distribuzione di Pareto generalizzata a dati climatici reali, evidenziando le sfide poste dalla stagionalità e dalla dipendenza temporale. La stratificazione stagionale, combinata con il declustering, ha permesso di ottenere stime affidabili nonostante la violazione delle ipotesi classiche.

Il confronto formale tra modello GPD ed esponenziale ha mostrato che, per tre stagioni su quattro, la semplificazione $\xi = 0$ è statisticamente giustificata. Solo per l'autunno il parametro di forma negativo risulta significativo, indicando l'esistenza di un limite fisico alle temperature minime raggiungibili in questa stagione.

I livelli di ritorno ottenuti forniscono informazioni utili per la pianificazione e la gestione del rischio climatico, pur con le cautele necessarie per le estrapolazioni a lungo termine.

Codice R

```
#####  
## GPD STRATIFICATO PER STAGIONE ##  
#####  
library(extRemes)  
library(GSODR)  
library(tidyverse)  
library(urca)  
library(lubridate)  
library(evd)  
  
set.seed(123)  
  
##### CARICAMENTO E PREPARAZIONE #####  
station <- nearest_stations(LAT = 45.46, LON = 9.19, distance = 50)[2, 1]  
milano <- get_GSOD(years = 1976:2018, station = station)  
str(milano)  
nrow(milano)  
ncol(milano)  
head(milano$YEARMODA)  
tail(milano$YEARMODA)  
n_years <- round(nrow(milano)/365)  
n_years == 2018 - 1976 + 1  
  
milano2 <- milano %>%  
  filter(!is.na(MIN)) %>%  
  mutate(  
    NEG_MIN = -MIN,  
    SEASON = factor(case_when(  
      MONTH %in% c(12, 1, 2) ~ "DJF",  
      MONTH %in% c(3, 4, 5) ~ "MAM",  
      MONTH %in% c(6, 7, 8) ~ "JJA",  
      MONTH %in% c(9, 10, 11) ~ "SON"  
    ), levels = c("DJF", "MAM", "JJA", "SON"))  
  )  
  
data_list <- split(milano2$NEG_MIN, milano2$SEASON)  
seasons <- names(data_list)  
  
##### ANALISI ESPLORATIVA #####  
  
# Verifica stazionarietà  
plot(milano$MIN, type = "l", col = "blue",  
      xlab = "Giorni", ylab = "Tmin (°C)", main = "Dati originali - Milano")  
  
par(mfrow = c(2, 2))  
for (s in seasons) plot(data_list[[s]], type = "l", col = "blue",  
                        xlab = "Giorni", main = s, ylab = "-Tmin (°C)")  
  
adf_results <- lapply(data_list, function(x) ur.df(x, type = "trend", lags = 3))  
for (s in names(adf_results)) {  
  print(summary(adf_results[[s]]))  
}  
  
# Verifica della dipendenza  
par(mfrow = c(4, 2), mar = c(4, 4, 2, 1))  
for (s in seasons) {
```

```

    acf(data_list[[s]], lag.max = 30)
    pacf(data_list[[s]], lag.max = 30)
}

##### STIMA DI GPD #####

# Scelta delle soglie
par(mfrow = c(2, 2))
for (s in seasons) mrlplot(data_list[[s]], main = s)

thresholds <- c(DJF = 5, MAM = 0.5, JJA = -12.5, SON = 0)

# stabilità al variare di r
r_values <- c(1, 2, 3, 4)
results <- expand.grid(r = r_values, Season = seasons, stringsAsFactors = FALSE)
results$u <- results$n_exc <- results$n_clust <- results$theta <- NA
results$sigma <- results$se_sigma <- results$xi <- results$se_xi <- NA

for (i in seq_len(nrow(results))) {
  r <- results$r[i]
  s <- results$Season[i]
  x <- data_list[[s]]
  u <- thresholds[s]

  # Declustering
  cluster_data <- evd::clusters(x, u = u, r = r, cmax = TRUE)

  n_exc <- sum(x > u)
  n_clust <- length(cluster_data)

  fit <- fevd(cluster_data, threshold = u, type = "GP")

  pars <- fit$results$par
  cov_mat <- solve(fit$results$hessian)
  ses <- sqrt(diag(cov_mat))

  results[i, c("u", "n_exc", "n_clust")] <- c(u, n_exc, n_clust)
  results$theta[i] <- round(n_clust / n_exc, 3)
  results$sigma[i] <- round(pars[1], 3)
  results$se_sigma[i] <- round(ses[1], 3)
  results$xi[i] <- round(pars[2], 3)
  results$se_xi[i] <- round(ses[2], 3)
}

print(results)

# Fit GPD con dati declusterizzati son r selezionato
r_opt <- 2

gpd_fits <- list()
for (s in seasons) {
  x <- data_list[[s]]
  u <- thresholds[s]
  clusters <- evd::clusters(x, u = u, r = r_opt, cmax = TRUE)
  n_exc <- sum(x > u)
  n_clust <- length(clusters)
  fit <- fevd(clusters, threshold = u, type = "GP")

```

```

    gpd_fits[[s]] <- list(fit = fit, theta = n_clust / n_exc,
                        n_exc = n_exc, n_clust = n_clust, u = u)
}

print(gpd_fits)

##### LRT: GPD vs ESPONENZIALE #####
lrt_results <- data.frame()

for (s in names(gpd_fits)) {
  fit_gpd <- gpd_fits[[s]]$fit
  fit_exp <- fevd(fit_gpd$x, threshold = fit_gpd$threshold, type = "Exponential")
  test <- lr.test(fit_exp, fit_gpd)

  lrt_results <- rbind(lrt_results, data.frame(
    Season = s,
    LR_Stat = round(test$statistic, 3),
    p_val_std = round(test$p.value, 4)
  ))
}

print(lrt_results)

##### MODELLI FINALI #####
# True a chi rifiuta H0 del LRT
use_gpd <- c(DJF = FALSE, MAM = FALSE, JJA = FALSE, SON = TRUE)

final_models <- list()
for (s in names(gpd_fits)) {
  gf <- gpd_fits[[s]]
  clusters <- gf$fit$x
  u <- gf$u

  if (use_gpd[s]) {
    fit <- gf$fit
    sigma <- fit$results$par[["scale"]]
    xi <- fit$results$par[["shape"]]
    V <- solve(fit$results$hessian)
    type <- "GPD"
  } else {
    fit <- fevd(clusters, threshold = u, type = "Exponential")
    sigma <- fit$results$par[["scale"]]
    xi <- 0
    n <- length(clusters)
    v_scale <- sigma^2 / n
    V <- matrix(c(v_scale, 0, 0, 0), nrow = 2, ncol = 2)
    type <- "Exp"
  }

  final_models[[s]] <- list(
    type = type,
    sigma = sigma,
    xi = xi,
    V = V,
    u = u,
    theta = gf$theta,
    n_exc = gf$n_exc,

```

```

        n_clust = gf$n_clust,
        data = clusters
    )
}

print(final_models)

##### DIAGNOSTICA #####
par(mfrow = c(4, 2), mar = c(4, 4, 2, 1))
for (s in names(final_models)) {
    model <- final_models[[s]]
    y <- model$data - model$u
    sigma <- model$sigma
    xi <- model$xi

    if (abs(xi) > 1e-6) {
        z <- (1 / xi) * log(1 + xi * y / sigma)
    } else {
        z <- y / sigma
    }

    z <- sort(z)
    n <- length(z)
    p_emp <- (1:n) / (n + 1)
    q_theo <- -log(1 - p_emp)
    p_model <- 1 - exp(-z)

    plot(p_emp, p_model, pch = 19, cex = 0.8,
         main = paste("PP -", s), xlab = "Empirica", ylab = "Modello")
    abline(0, 1, col = "red", lwd = 2)

    plot(q_theo, z, pch = 19, cex = 0.8,
         main = paste("QQ -", s), xlab = "Exp(1)", ylab = "Standardizzati")
    abline(0, 1, col = "red", lwd = 2)
}
par(mfrow = c(1, 1))

##### RETURN LEVELS CON IC #####
return_level_ci <- function(model, T_years, n_per_year, zeta_u, alpha = 0.05) {
    sigma <- model$sigma
    xi <- model$xi
    u <- model$u
    V <- model$V

    m <- T_years * n_per_year * zeta_u * model$theta

    if (abs(xi) > 1e-6) {
        z_T <- u + (sigma / xi) * (m^xi - 1)

        # Calcolo delle derivate parziali per IC
        dz_dsigma <- (m^xi - 1) / xi
        dz_dxi <- (sigma / xi) * (m^xi * log(m) - (m^xi - 1) / xi)
    } else {
        z_T <- u + sigma * log(m)

        # Calcolo delle derivate parziali per IC
        dz_dsigma <- log(m)
        dz_dxi <- 0
    }
}

```

```

}

# Metodo delta per IC
grad <- c(dz_dsigma, dz_dxi)
se_z <- sqrt(t(grad) %*% V %*% grad)
z_crit <- qnorm(1 - alpha/2)

data.frame(z_T = z_T, se = as.numeric(se_z),
           ci_lower = as.numeric(z_T - z_crit * se_z),
           ci_upper = as.numeric(z_T + z_crit * se_z))
}

# Selezione degli anni
T_ret <- c(10, 20, 50, 100)
rl_results <- data.frame()

for (s in names(final_models)) {
  mod <- final_models[[s]]
  n_obs <- length(data_list[[s]])
  n_per_year <- n_obs / n_years
  zeta_u <- mod$n_exc / n_obs

  for (T in T_ret) {
    rl <- return_level_ci(mod, T, n_per_year, zeta_u)
    rl_results <- rbind(rl_results, data.frame(
      Season = s, T_years = T,
      Tmin = round(-rl$z_T, 2),
      CI_lower = round(-rl$ci_upper, 2),
      CI_upper = round(-rl$ci_lower, 2)
    ))
  }
}

for(s in unique(rl_results$Season)) {
  print(rl_results %>% filter(Season == s))
}

```

Riferimenti bibliografici

- [1] Coles, S. (2001). *An Introduction to Statistical Modeling of Extreme Values*. Springer.
- [2] Beirlant, J., Goegebeur, Y., Segers, J., & Teugels, J. (2004). *Statistics of Extremes: Theory and Applications*. Wiley.
- [3] Smith, R. L. (1985). Maximum likelihood estimation in a class of nonregular cases. *Biometrika*, 72(1), 67–90.
- [4] Leadbetter, M. R., Lindgren, G., & Rootzén, H. (1983). *Extremes and Related Properties of Random Sequences and Processes*. Springer.
- [5] Davison, A. C., & Smith, R. L. (1990). Models for exceedances over high thresholds. *Journal of the Royal Statistical Society, Series B*, 52(3), 393–442.
- [6] Sparks, A. H., Hengl, T., & Nelson, A. (2025). *GSODR: Global Summary Daily Weather Data in R*. R package version 5.0.0. <https://doi.org/10.5281/zenodo.1040727>
- [7] Gilleland, E., & Katz, R. W. (2016). extRemes 2.0: An Extreme Value Analysis Package in R. *Journal of Statistical Software*, 72(8), 1–39. <https://doi.org/10.18637/jss.v072.i08>
- [8] Stephenson, A. G. (2002). evd: Extreme Value Distributions. *R News*, 2(2), 31–32. <https://CRAN.R-project.org/doc/Rnews/>
- [9] Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., ... & Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- [10] Pfaff, B. (2008). *Analysis of Integrated and Cointegrated Time Series with R* (2nd ed.). Springer. <https://www.pfaffikus.de>
- [11] Grolemund, G., & Wickham, H. (2011). Dates and Times Made Easy with lubridate. *Journal of Statistical Software*, 40(3), 1–25. <https://doi.org/10.18637/jss.v040.i03>
- [12] R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. <https://www.R-project.org/>
- [13] Posit Team (2025). *RStudio: Integrated Development Environment for R*. Posit Software, PBC, Boston, MA. <https://posit.co/products/open-source/rstudio/>